Instructor Feedback – Project Progress 1

Project: FoonAlert – PM2.5 Forecasting System

🔷 ภาพรวม

นี่เป็น Progress 1 ที่ "โครงสร้างครบและคิดเชิงระบบได้ดี" โดยเฉพาะ:

- Problem framing ชัด (district-level forecasting) (หน้า 1)
- Time-based split ถูกต้องสำหรับ time-series (หน้า 4)
- Privacy/PDPA assessment ทำครบถ้วน (หน้า 4–5)
- Baseline เลือก Persistence Model เหมาะสม (หน้า 8)
- มีการเปรียบเทียบหลายโมเดล และวิเคราะห์ trade-off (หน้า 11–13)
- เลือกโมเดลโดยมีเหตุผลเชิงระบบ ไม่ใช่แค่ metric สูงสุด (หน้า 13–14)

โดยรวมถือว่าเป็นงานที่ mature มากสำหรับ Progress 1

🔷 จุดที่ทำได้ดีมาก

1️⃣ Baseline ถูกต้องตามหลัก Time-Series

การใช้ **Persistence model ($\hat{y}_{t+1} = y_t$)** เป็น baseline (หน้า 8)

นี่เป็น industry-standard และสะท้อนความเข้าใจ time-series forecasting ดีมาก

หลายทีมมักเลือก Linear Regression เป็น baseline ซึ่งไม่ถูกต้องเท่านี้

2️⃣ Feature Engineering มีความเข้าใจ temporal dependency

หน้า 7 แสดง lag features + rolling mean/std + diff features

feature set นี้เหมาะสมกับ PM2.5 ซึ่งมี autocorrelation และ seasonality

---

3️⃣ การเลือก Model มีเหตุผลเชิงระบบ

แม้ Ridge จะมี RMSE ดีสุด

แต่ทีมเลือก Random Forest เพราะ:

- MAE ต่ำสุด
- Robust
- ไม่ต้อง scaling
- Inference เร็ว
- Deploy ง่าย (joblib)

นี่เป็น system-level thinking ที่ดีมาก

4️⃣ Ethical Risk Framing ดี

หน้า 5 อธิบาย False Negative vs False Positive risk ชัดเจน

และเสนอ mitigation เช่น confidence interval + disclaimer

ถือว่า Responsible ML framing ดี

🔷 จุดที่ควรพัฒนา

🚨 1️⃣ Baseline Definition ยังสับสนเล็กน้อย

หน้า 8 ระบุ Baseline = Persistence

แต่หน้า 11 ตารางเปรียบเทียบใช้ "Linear Regression (Baseline)"

ควรทำให้ชัดเจนว่า:

- Baseline 1 = Persistence
- Baseline 2 = Linear Regression

หรือเลือก baseline เดียวให้ชัด เพื่อไม่ให้เกิด confusion ใน Final Report

---

🚨 2️⃣ ต้องระบุ Forecast Horizon ชัดเจน

ในหน้า 8 มีทั้ง:

- $\hat{y}_{t+24} = y_t$
- $\hat{y}_{t+1} = y_t$

ควรระบุชัดว่า:

- พยากรณ์ 1 วันล่วงหน้า?
- หรือ 24 ชั่วโมงล่วงหน้าแบบ hourly?

Horizon ส่งผลต่อ difficulty และ metric interpretation อย่างมาก

🚨 3️⃣ ยังไม่มี Confidence Interval จริง

ในหน้า 5 เสนอว่าจะแสดง confidence interval

แต่ยังไม่มี:

- Prediction interval method
- Quantile regression
- Bootstrapped CI

ใน regression system ที่กระทบสุขภาพ

uncertainty quantification สำคัญมาก

🚨 4️⃣ ยังไม่มี Error Analysis ช่วง Pollution Spike

หน้า 9 ระบุว่าจะวิเคราะห์ช่วง:

- < 35
- 35–75

- 75 μg/m³

แต่ยังไม่มี metric แยกตาม regime

ควรเพิ่ม:

- MAE เฉพาะช่วง high pollution
- Worst-case error
- 95th percentile error

เพราะ error ช่วง spike สำคัญกว่าค่าเฉลี่ย

🚨 5️⃣ ยังไม่มี Drift Monitoring Plan ชัดเจน

มี assumption เรื่อง no structural break (หน้า 6)

แต่ใน production จริง:

- ไฟไหม้
- Construction surge
- El Niño

ควรเพิ่ม:

- Rolling MAE monitoring
- PSI (population stability index)
- Retrain trigger condition

🚨 6️⃣ XGBoost Performance ต่ำกว่าคาด

จากหน้า 11–12:

- XGBoost RMSE แย่สุด
- R^2 ต่ำสุด

ควร:

- ตรวจ hyperparameter tuning

- ตรวจ data leakage
- ตรวจ scaling
- หรือ feature interaction ไม่เพียงพอ

เพื่อให้แน่ใจว่าไม่ได้เกิด training artifact

🔷 คำแนะนำเชิงกลยุทธ์สำหรับ Progress ถัดไป

ผมแนะนำ roadmap 5 ข้อ:

1️⃣ ชัดเจนเรื่อง forecast horizon

2️⃣ เพิ่ม error analysis แยกตาม pollution regime

3️⃣ เพิ่ม prediction interval / uncertainty estimation

4️⃣ เพิ่ม monitoring & retraining policy

5️⃣ ทำ feature importance plot (Random Forest) เพื่อ explain model behavior

ถ้าทำครบ 5 ข้อนี้

ระบบจะดูเป็น "production-grade environmental ML system" มากขึ้นทันที

🔷 สรุปในฐานะอาจารย์

ทีมนี้ทำได้ดีมาก:

- Time-series split ถูกต้อง
- Baseline แข็งแรง
- Feature engineering ดี
- Model selection มีเหตุผล
- Ethical framing ครบ

สิ่งที่ต้องเพิ่มคือ:

Uncertainty + Regime-specific analysis + Monitoring plan

ถ้าพัฒนาต่อในทิศทางนี้

FoonAlert มีศักยภาพสูงมากที่จะเป็น demo ระบบพยากรณ์เชิงพื้นที่ที่ครบวงจรครับ 👍